注意力机制的工程化落地

摘要：本文讨论 Transformer 类模型在真实业务中的落地路径，重点分析推理成本、长序列建模与工程折衷。

一、引言

自注意力机制把序列建模从循环结构里解放出来，但它并没有消灭序列长度带来的二次复杂度。